Guion Técnico para Trabajo Final de Máster

UrgeNurse Agent: Plataforma Multi-Agente Local para Soporte a la Documentación de Enfermería en Urgencias mediante OCR, ASR y Modelos de Lenguaje Locales

Autor: Marlon Cárdenas Bonett
Equipo de desarrollo: Luis Edilberto Ortiz, Cesar Adrian Robledo y Luis Manuel Barrios

Máster Universitario en Análisis y Visualización de Datos Masivos / Visual Analytics and Big Data
Universidad Internacional de La Rioja — Escuela Superior de Ingeniería y Tecnología

Sobre este documento

Este documento es una propuesta técnica orientada a guiar al equipo de estudiantes en el desarrollo de su Trabajo de Fin de Máster. No pretende redactar la memoria por ellos, ni dictar exactamente lo que deben hacer, sino ofrecer el marco conceptual y técnico desde el que construir su propia propuesta. El estudiante es el agente activo: investiga, decide, propone y justifica cada elección. Este documento señala el punto de partida, los límites razonables del proyecto y el estándar de calidad esperado en cada sección de la memoria.

Un error frecuente en los TFM de este tipo es confundir **"trabajar con inteligencia artificial"** con simplemente usar una librería o conectar una API. El valor académico reside en la comprensión profunda de por qué una tecnología es adecuada para un problema, cómo se integran varios sistemas heterogéneos de forma coherente, y qué resultados medibles demuestra el sistema construido. Esa argumentación es lo que distingue un TFM de calidad de un ejercicio técnico superficial.

Presentación del problema: por qué enfermería en urgencias

Los servicios de urgencias hospitalarias son entornos de alta exigencia cognitiva y documental. Cuando un paciente llega a urgencias, la enfermera de triage es la primera persona que lo evalúa. En ese primer contacto —que en servicios saturados puede durar menos de cuatro minutos— debe registrar los signos vitales, valorar el nivel de dolor según la escala EVA, identificar el motivo principal de consulta, asignar un nivel de prioridad según el sistema de triage utilizado (en España se usan principalmente el Sistema Español de Triage, el Manchester Triage System y el ESI de origen norteamericano), y volcar todo ese registro en el sistema de información del hospital.

Este proceso, que parece simple, está sistemáticamente documentado en la literatura como uno de los principales focos de carga cognitiva y error en urgencias. Estudios con datos de MIMIC-IV-ED —la mayor base de datos pública de visitas a urgencias, con más de 425.000 episodios— muestran que el 28% de los triages iniciales son revisados y modificados en menos de 60 minutos, lo que implica que el primer registro fue incompleto o impreciso. Más allá del triage, la enfermera documenta la evolución del paciente durante toda su estancia: toma de constantes periódicas, administración de medicación, registro de incidencias, y —lo que con frecuencia más errores produce— el handover al cambio de turno.

El handover de enfermería es la transferencia verbal de información entre la enfermera que termina su turno y la que lo comienza. En un servicio de urgencias activo, este proceso puede durar entre 10 y 20 minutos y cubre simultáneamente todos los pacientes presentes. La estructura SBAR (Situation, Background, Assessment, Recommendation) es el estándar internacional recomendado por la OMS para garantizar que este traspaso sea completo y sistemático. Sin embargo, en la práctica diaria el handover es frecuentemente oral, desestructurado y dependiente de la memoria del profesional. Estudios de calidad asistencial muestran que hasta el 20% de la información crítica se pierde en handovers sin estructura SBAR.

Este es el problema que UrgeNurse Agent aborda: la carga documental y la pérdida de información en los dos procesos de enfermería más críticos de urgencias —el triage inicial y el handover de turno— mediante un pipeline tecnológico local, multi-modal y acotado que asiste (no sustituye) a la enfermera.

Alcance de la solución: qué hace y qué no hace

Antes de entrar en la arquitectura técnica, es fundamental que el estudiante entienda y argumente el alcance del sistema. **UrgeNurse Agent no es un sistema de diagnóstico clínico**. No prescribe medicación, no interpreta resultados analíticos desde el punto de vista médico, ni toma decisiones sobre el estado del paciente. Su función es exclusivamente documental y de soporte a la continuidad asistencial: procesa información que ya existe (datos de triage, documentos clínicos entrantes, audio de handover), la estructura, la valida en términos formales (¿está completo el registro?, ¿coinciden los datos entre documentos?, ¿el nivel ESI es consistente con los signos vitales registrados?) y genera outputs documentales listos para que la enfermera los revise, corrija si es necesario, y utilice.

Esta acotación no es una limitación académica, sino una decisión de diseño que debe argumentarse en la memoria. Los sistemas de IA que apoyan procesos clínicos sin tomar decisiones terapéuticas se ubican en la categoría de soporte a la decisión con supervisión humana obligatoria, lo que en el marco del AI Act europeo les permite operar con requisitos de transparencia y trazabilidad —que el sistema satisface generando informes con fuentes explícitas— sin necesidad de los procesos de validación clínica que requeriría un sistema de diagnóstico autónomo.

El sistema se delimita a tres módulos, cada uno responsable de un output concreto:

Módulo 1 — Validación de triage ESI desde datos tabulares del EHR. El estudiante implementa un agente que lee los registros de triage del paciente (signos vitales, motivo de consulta, nivel de dolor), los evalúa frente a las reglas del ESI y genera alertas cuando los datos son inconsistentes con el nivel asignado.

Módulo 2 — Estructuración de documentos clínicos entrantes mediante OCR. Cuando llegan al servicio documentos externos (analíticas de otro centro, informes previos, resultados de ECG en papel), la enfermera los recibe pero frecuentemente no tiene tiempo de integrarlos en la historia activa. El agente documental procesa estos PDFs o imágenes, extrae los campos relevantes para enfermería (no todos los datos del documento, sino los que la enfermera necesita: analíticas clave, medicación habitual, alergias) y los incorpora al registro estructurado del paciente.

Módulo 3 — Transcripción y estructuración del handover mediante ASR local. La enfermera graba o dicta el handover verbalmente (2-5 minutos de audio). El agente ASR transcribe ese audio con Faster-Whisper localmente, diariza los turnos de habla (enfermera saliente vs. entran te), y el LLM local extrae la estructura SBAR, completando las cuatro secciones, marcando lo que falta y generando el documento de traspaso estructurado.

Por qué local y en CPU: la justificación técnica

Esta es una de las decisiones de diseño más relevantes del proyecto y el estudiante debe argumentarla con solidez en la memoria. Los sistemas basados en cloud —enviando documentos o audio a APIs como OpenAI o Azure Cognitive Services— son funcionales y rápidos, pero presentan dos problemas fundamentales en el contexto clínico. El primero es normativo: los datos de salud son datos de categoría especial bajo el RGPD, y su transferencia a un tercero requiere acuerdos de procesamiento explícitos, análisis de impacto (DPIA) y justificación de la base legal. El segundo es de soberanía institucional: los hospitales públicos y muchas mutuas privadas tienen políticas que prohíben que datos de pacientes salgan de su infraestructura.

Un sistema que ejecuta todos sus modelos localmente —en el servidor del propio servicio de urgencias, o incluso en un portátil de alta gama— elimina ambos problemas. La apuesta por CPU (en lugar de GPU) es igualmente razonada: la infraestructura GPU en entornos sanitarios es excepcional, mientras que cualquier servidor de propósito general o

workstation médica tiene CPU suficiente para ejecutar modelos cuantizados de 7B parámetros. Faster-Whisper large-v3 con cuantización INT8 procesa un audio de 3 minutos en aproximadamente 45 segundos en CPU. Mistral-7B con llama.cpp en Q4_K_M genera una respuesta SBAR completa en 20-30 segundos en CPU. Estos tiempos son perfectamente aceptables para un contexto de uso en el que el handover dura 15-20 minutos.

El estudiante debe replicar y documentar estos tiempos en su entorno específico, convertirlos en una tabla comparativa en la memoria y argumentar si son suficientes para el caso de uso. Si no lo fueran, el trabajo futuro incluiría optimizaciones (GPU offloading parcial, reducción de modelo a 3B parámetros para tareas más simples). Esta reflexión crítica es exactamente el tipo de contribución académica que se espera.

Orientación para la Introducción de la Memoria

La introducción tiene que cumplir una función muy concreta: convencer al lector de que el problema existe, de que es relevante, y de que la solución propuesta es una contribución real. Para hacerlo bien, el estudiante necesita anclar cada afirmación en datos verificables.

Sobre la motivación: no basta con decir que "enfermería tiene mucha carga documental". Hay que cuantificarlo. Por ejemplo: estudios de tiempos en servicios de urgencias europeos muestran que entre el 35% y el 45% del tiempo de la enfermera de urgencias se destina a documentación. En un turno de 8 horas, eso son entre 2,8 y 3,6 horas de escritura clínica. El estudiante debe buscar estas cifras en literatura científica (PubMed, CINAHL, Cochrane) y citarlas con rigor APA. MIMIC-IV-ED es especialmente útil aquí porque permite calcular estadísticas descriptivas reales sobre tiempos de triage, revisiones de nivel ESI y frecuencia de cada motivo de consulta, lo que aporta contexto cuantitativo al problema.

Sobre el planteamiento del trabajo: aquí el estudiante debe describir brevemente qué propone construir y por qué esa construcción resuelve el problema descrito. La clave es la especificidad: no "un sistema de IA para urgencias", sino "un pipeline multi-agente que procesa las tres fuentes de datos más críticas del flujo nursing ED —CSV de triage, PDF de analíticas y audio de handover— para generar tres outputs estandarizados: triage ESI validado, nota nursing estructurada y SBAR de handover, ejecutando todos los modelos en local sin dependencia de red ni de servicios externos".

Sobre la estructura del trabajo: esta sección es breve (media página) pero el estudiante tiende a hacerla demasiado genérica ("el capítulo 2 trata el estado del arte…"). Debe ser específica: "el capítulo 2 revisa los tres ejes tecnológicos del sistema (triage automatizado, OCR clínico y ASR médico), compara las soluciones existentes con UrgeNurse Agent y justifica la brecha que este TFM llena". Esa especificidad demuestra que el estudiante ha planificado el trabajo antes de empezar a escribirlo.

Orientación para el Estado del Arte

Esta sección es la que más esfuerzo investigador requiere y la que con más frecuencia los estudiantes hacen de forma superficial. Listar herramientas con una frase cada una no es estado del arte: es un catálogo. El estado del arte real responde a la pregunta "¿qué se ha intentado antes para resolver este problema, hasta dónde se ha llegado y qué sigue sin resolverse?". La respuesta a esa pregunta es la que justifica la existencia del proyecto.

Eje 1: Triage asistido en urgencias. Existen varios trabajos que usan MIMIC-IV-ED para entrenar modelos predictivos de nivel ESI o de deterioro del paciente. El estudiante debe revisar al menos 4-5 de estos trabajos, comparar sus enfoques (¿usan solo signos vitales?, ¿añaden texto libre?, ¿son modelos ML clásicos o LLM?) y extraer qué funciona y qué limitaciones presentan. La conclusión importante para UrgeNurse es que estos trabajos no integran la validación de triage con la generación de documentación; son modelos de predicción, no sistemas de soporte documental. Esa diferencia es la que el estudiante debe articular con claridad.

Eje 2: OCR y extracción de información de documentos clínicos. Docling (IBM, 2024) es la herramienta más relevante del ecosistema open source actual para este propósito. Es capaz de procesar PDFs con layout complejo —incluyendo tablas de analíticas, formularios multi-columna, informes de ECG— y exportar la información en formato Markdown estructurado o JSON, preservando la jerarquía del documento. El estudiante debe instalar Docling, ejecutarlo sobre al menos 20 documentos clínicos sintéticos de diferentes tipos, medir su precisión de extracción en los campos clave (Hb, Creatinina, Glucosa, Grupo sanguíneo) y comparar esos resultados con los de una alternativa como MinerU. Esta comparación empírica, presentada en tabla con métricas cuantitativas, tiene mucho más valor académico que una descripción cualitativa de las herramientas.

Eje 3: ASR para audio clínico. Faster-Whisper es la implementación más eficiente de Whisper para CPU. El estudiante debe ejecutarlo sobre el dataset Synthetic Nursing Handoff (300 audios WAV con transcripción de referencia), calcular el Word Error Rate (WER) global y específico para terminología de enfermería (nombres de medicamentos, valores numéricos, abreviaturas clínicas) y comparar con la variante base de Whisper para justificar la elección. Es importante destacar —y el estudiante debe haberlo leído— que Whisper tiene un conocido problema de alucinación en silencios y ruido de fondo, documentado por investigadores del MIT. Ignorar este riesgo en la memoria sería un error académico grave; el estudiante debe describir qué medida implementa para mitigarlo (filtro VAD, umbral de confianza por palabra, post-procesamiento con NER).

Eje 4: LLM locales para síntesis clínica. NurseLLM (2025) es el primer modelo de lenguaje específicamente entrenado en competencias de enfermería, publicado en arXiv en octubre de 2025. El estudiante debe revisarlo, entender en qué tareas fue evaluado y compararlo con Mistral-7B general. La conclusión probable es que Mistral-7B, correctamente guiado con un prompt estructurado SBAR, funciona tan bien o mejor en la tarea específica de generación de handover porque el contexto del prompt es más determinante que el entrenamiento especializado para tareas de generación estructurada. Esa conclusión, si el estudiante la demuestra empíricamente, es una contribución académica válida.

Conclusión del estado del arte: el estudiante debe cerrar este capítulo respondiendo explícitamente: "Ninguna herramienta existente en el ecosistema open source integra estas tres modalidades (tabular + PDF + audio) en un pipeline nursing ED local orientado a SBAR. Las herramientas existentes abordan cada modalidad por separado. UrgeNurse Agent llena ese vacío con una arquitectura de agentes orquestados por LangGraph, ejecutando todos los modelos en CPU sin dependencia de red". Esa frase, respaldada por la revisión anterior, es la justificación técnica del proyecto.

Orientación para Objetivos y Metodología

Sobre el objetivo general

El objetivo general debe ser medible y específico. Un ejemplo inadecuado sería: "Desarrollar un sistema de apoyo a enfermería en urgencias". Eso no dice nada verificable. Un objetivo correcto sería: "Desarrollar y evaluar UrgeNurse Agent, un pipeline multi-agente local en CPU que procesa datos tabulares de triage ESI (MIMIC-IV-ED), documentos PDF de analíticas (sintéticos) y audio de handover (Synthetic Nursing Handoff Dataset) para generar triage ESI validado, notas nursing estructuradas y resúmenes SBAR, alcanzando WER < 15% en transcripción de audio clínico, F1 ≥ 0.85 en extracción de campos nursing y completitud SBAR ≥ 90%".

Esa formulación tiene tres virtudes: describe el sistema, especifica los datos usados y establece criterios de éxito cuantificables. Que el estudiante alcance o no esas métricas durante el desarrollo es secundario; lo importante es que haya establecido un criterio contra el que medir su trabajo.

Sobre los objetivos específicos

La plantilla del Máster indica que los objetivos específicos deben formularse con verbo en infinitivo y cubrir los diferentes pasos del objetivo general. Para este proyecto, los objetivos razonables son entre 8 y 10. El riesgo habitual

es formularlos demasiado vagos ("Analizar herramientas de OCR") o demasiado ambiciosos ("Implementar un sistema de diagnóstico de sepsis"). El equilibrio está en objetivos que sean técnicamente concretos, alcanzables en el tiempo del TFM y verificables con métricas.

Un ejemplo de objetivo bien formulado: "Implementar el módulo de transcripción local basado en Faster-Whisper large-v3 con filtro VAD y umbral de confianza por palabra ≥ 0.7, evaluado sobre el Synthetic Nursing Handoff Dataset con cálculo de WER global y específico para términos farmacológicos y valores numéricos". Este objetivo describe exactamente qué se hace, cómo y con qué se mide.

Sobre la metodología

La metodología es el mapa de cómo se desarrolla el trabajo. Para este proyecto es adecuado usar **CRISP-DM adaptado**, dado que el proyecto es fundamentalmente un sistema de análisis y procesamiento de datos. Las fases son: comprensión del dominio (nursing ED), comprensión de los datos (MIMIC-IV-ED, handoff sintético), preparación de los datos (preprocessing, anonimización verificada), modelado (implementación de agentes), evaluación (métricas) y despliegue (demo local).

Combinado con sprints Scrum de dos semanas, el estudiante tiene un marco de referencia claro: cada sprint tiene un entregable concreto (un agente funcional, una métrica calculada, una sección de la memoria redactada) y un mecanismo de coordinación grupal explícito. La plantilla del Máster requiere que esto se documente en la tabla de organización del trabajo grupal.

Orientación para el Marco Normativo

El marco normativo en este proyecto es especialmente relevante por dos razones que el estudiante debe desarrollar con detalle, no simplemente mencionar.

La primera razón es que los datos clínicos —incluyendo datos de urgencias— son datos de categoría especial según el artículo 9 del RGPD (Reglamento UE 2016/679), lo que implica el nivel más alto de protección. El estudiante debe explicar por qué el uso de MIMIC-IV-ED no supone un problema normativo: el dataset fue construido bajo protocolos IRB aprobados, los datos fueron desidentificados según el método Safe Harbor de HIPAA antes de ser publicados, y el acceso requiere firma de un Data Use Agreement (DUA) que especifica que los datos se usarán solo con fines de investigación. El estudiante debe adjuntar el DUA firmado como evidencia en el repositorio (o referenciarlo en la memoria).

La segunda razón es que el audio de handover de enfermería contiene datos de voz, que bajo el RGPD se consideran datos biométricos si permiten identificar al individuo. El dataset Synthetic Nursing Handoff resuelve este problema porque los audios son grabaciones de actores simulando handovers, sin datos de pacientes ni enfermeras reales. El estudiante debe argumentar explícitamente en el Anexo A de Privacidad por qué el uso exclusivo de datasets sintéticos o públicamente desidentificados es la elección metodológica correcta desde el punto de vista normativo, y cómo esa elección hace el sistema demostrable sin riesgos legales.

El AI Act europeo (Reglamento UE 2024/1689) es también aplicable y debe discutirse. Los sistemas que asisten en procesos que afectan a la salud de personas pueden clasificarse como sistemas de alto riesgo (Anexo III). Sin embargo, UrgeNurse Agent está diseñado explícitamente como herramienta de soporte documental sin decisión clínica autónoma, lo que matiza su clasificación. El estudiante debe argumentar este posicionamiento y documentar qué medidas de transparencia implementa el sistema (informes con fuentes explícitas, revisión humana obligatoria de todos los outputs).

Orientación para el Desarrollo Específico de la Contribución

Este es el capítulo más extenso de la memoria y el que tiene mayor peso en la evaluación. Debe cubrir entre 25 y 35 páginas y demostrar que el estudiante domina técnicamente lo que construyó, por qué tomó las decisiones que tomó y qué resultados obtuvo. No es suficiente con describir el código: hay que argumentar las decisiones de diseño, comparar alternativas y analizar los resultados.

La arquitectura del sistema: cómo explicarla bien

La arquitectura no es un diagrama de cajas y flechas; es una decisión de diseño que debe justificarse. El estudiante debe explicar por qué usa LangGraph en lugar de una secuencia de llamadas de función simples. La respuesta es que los agentes necesitan compartir estado (el PacienteState acumulado a lo largo del pipeline), y que LangGraph permite definir ese estado como un objeto tipado que persiste entre nodos, con soporte nativo para condicionales (si el ASR falla, el agente SBAR puede operar solo con texto) y para ciclos de retry (si la extracción OCR tiene baja confianza, el agente puede reintentar con un modelo alternativo). Esa argumentación, citando la documentación de LangGraph y comparándolo con alternativas como CrewAI o LangChain Chains simples, demuestra que la elección fue razonada, no arbitraria.

El estado compartido entre agentes es el concepto arquitectónico más importante que el estudiante debe explicar con claridad. Imagina que la enfermera sube simultáneamente el CSV de triage, un PDF de analíticas y un audio de handover de 3 minutos. El orquestador LangGraph activa los tres agentes en paralelo (Agente Triage, Agente Documental, Agente ASR), cada uno procesa su input y escribe sus resultados en el PacienteState compartido. Cuando los tres agentes han completado su trabajo, el Agente SBAR lee el estado completo —datos de triage, campos extraídos del PDF y transcripción del audio— y genera el resumen SBAR integrando las tres fuentes. El estudiante debe incluir un diagrama de secuencia (no solo de arquitectura) que muestre este flujo temporal, con las fases paralelas y la fase de síntesis final.

El agente de triage ESI: cómo el estudiante debe desarrollarlo

El primer módulo, responsabilidad del Estudiante 1, es el más directo técnicamente, pero requiere un trabajo de dominio previo que el estudiante no puede omitir. El ESI (Emergency Severity Index) tiene un algoritmo de decisión público y documentado: cinco niveles de prioridad basados en criterios específicos de signos vitales, estado mental, recursos necesarios estimados y dolor. El estudiante debe estudiar ese algoritmo antes de escribir una línea de código, porque sin entenderlo no puede validar que su implementación sea correcta.

Desde el punto de vista de datos, MIMIC-IV-ED proporciona los campos exactos que necesita: acuity (nivel ESI asignado), heart_rate, resp_rate, sbp (systolic blood pressure), temperature, o2sat, pain y chiefcomplaint (motivo de consulta en texto libre). El estudiante debe explorar el dataset, calcular las estadísticas descriptivas de estos campos por nivel ESI (¿cuáles son los rangos típicos de FC para ESI 1, 2, 3?), identificar los umbrales que discriminan bien entre niveles y usar ese análisis para construir las reglas de validación. Esto no es un modelo de machine learning que "aprende" los umbrales: es un sistema de reglas basado en el estándar clínico, validado contra datos reales de MIMIC-IV-ED.

La contribución del estudiante en este módulo es doble: la implementación del validador ESI y la evaluación de su concordancia con los niveles asignados en MIMIC-IV-ED. Si el sistema propone ESI 2 y el registro real tiene ESI 3, eso no necesariamente significa que el sistema es incorrecto (puede que el triage original fuera conservador), pero sí es un resultado que el estudiante debe analizar y discutir.

El agente documental: cómo el estudiante debe desarrollarlo

El Estudiante 2 se responsabiliza de este módulo. El punto de partida es entender que los documentos clínicos que llegan a urgencias desde otros centros son tremendamente heterogéneos: cada laboratorio, cada clínica privada, cada hospital tiene su propio formato de informe analítico. Un documento de analíticas del Hospital A puede tener los valores en una tabla de dos columnas; el del Hospital B los lista en párrafo; el del laboratorio privado los presenta en un formato trifold con logo corporativo. Docling fue diseñado precisamente para manejar esta heterogeneidad: su

pipeline de procesamiento detecta automáticamente el layout del documento, extrae tablas como estructuras de datos y preserva las relaciones entre encabezados de columna y valores. Consulta el github para ampliar conocimientos.

El trabajo del estudiante es generar un conjunto de documentos analíticos sintéticos en al menos cuatro formatos de layout distintos —simples para empezar, complejos después— ejecutar Docling sobre ellos, medir qué porcentaje de los campos clave (los 10-15 parámetros analíticos más relevantes para urgencias: hemoglobina, creatinina, glucosa, sodio, potasio, troponina, PCR, INR, plaquetas, leucocitos) se extraen correctamente, y analizar en qué tipos de layout la extracción falla. Esa evaluación cuantitativa, con su análisis de error, es la contribución central de este módulo.

Una vez que los campos están extraídos, el agente documental debe decidir cuáles son relevantes para enfermería en urgencias. No todos los campos de una analítica son prioritarios: la enfermera de urgencias necesita identificar inmediatamente valores fuera de rango crítico (hemoglobina < 7 g/dL, creatinina > 5 mg/dL, glucosa > 500 mg/dL) porque esos son los que pueden requerir una actuación inmediata. El agente implementa una capa de clasificación de urgencia analítica usando el LLM local: dado el valor extraído y los rangos de referencia, ¿es este valor normal, alterado o crítico? Esta clasificación se incorpora al PacienteState con el nivel de alerta correspondiente.

El agente ASR y SBAR: cómo el estudiante debe desarrollarlo

El Estudiante 3 tiene el módulo más novedoso y técnicamente más delicado. El proceso completo tiene cuatro etapas que deben implementarse y evaluarse de forma independiente antes de integrarse: transcripción ASR, diarización de hablantes, extracción SBAR con LLM, y validación de completitud.

La transcripción con Faster-Whisper es el primer paso. El estudiante debe entender que Faster-Whisper no es simplemente "Whisper más rápido": usa CTranslate2 para optimizar la inferencia en CPU con cuantización INT8, lo que puede reducir el uso de memoria a la mitad y aumentar la velocidad entre 2x y 4x respecto a Whisper puro, con pérdida mínima de precisión. El parámetro vad_filter=True es esencial en contexto clínico: activa el Voice Activity Detection que filtra los silencios antes de pasarlos al modelo, eliminando el vector principal de alucinaciones. El estudiante debe medir el impacto de este parámetro: calcular el WER sobre el dataset de handoff sintético con y sin VAD, y documentar la diferencia. Si la diferencia es significativa (por ejemplo, WER pasa de 18% a 11% con VAD), eso es un resultado publicable en sí mismo. Revisar el siguiente contenido modal.

La diarización —identificar quién habla en cada momento— es más compleja y el estudiante debe evaluar si es necesaria para el caso de uso. En un handover nursing, habitualmente habla solo la enfermera saliente mientras la entrante escucha y pregunta puntualmente. La diarización con pyannote-audio funciona bien en condiciones controladas, pero requiere modelos adicionales que consumen memoria y tiempo. El estudiante puede tomar la decisión justificada de no implementar diarización en la versión principal del sistema, documentarla como limitación y señalar cómo se abordaría en trabajo futuro. Esa decisión razonada tiene más valor académico que una implementación apresurada de diarización que funcione mal.

La extracción SBAR con el LLM es donde el diseño del prompt es absolutamente crítico. Un prompt mal diseñado produce SBAR incompletos, sin citas textuales de la transcripción, con alucinaciones (el modelo "inventa" detalles que no estaban en el audio). El estudiante debe diseñar el prompt con restricciones explícitas: solo citar texto que aparezca verbatim en la transcripción con su timestamp, marcar explícitamente qué secciones SBAR están vacías si no hay información, no inferir ni completar información no mencionada. El estudiante debe evaluar al menos tres versiones del prompt sobre el mismo conjunto de audios y documentar cuál produce mejores resultados y por qué.

Los Datasets: cómo usarlos y qué aportan

Esta sección es crucial porque garantiza la autonomía del proyecto respecto a colaboración clínica. El estudiante debe entender en profundidad cada dataset antes de usarlo.

MIMIC-IV-ED v2.2 (PhysioNet) es la principal fuente de datos tabulares de urgencias del mundo. Sus tablas más relevantes para este proyecto son triage (nivel ESI, signos vitales, motivo de consulta), edstays (tiempos de llegada, triage, alta), medrecon (medicación reconciliada en urgencias) y pyxis (medicación administrada en urgencias). El acceso requiere registro en PhysioNet y completar el curso CITI de protección de datos humanos (gratuito, ~4 horas online). El proceso completo tarda entre 3 y 7 días. Por eso el estudiante debe iniciarlo en la semana 1 del proyecto, no esperar. Mientras tanto, el **MIMIC-IV-ED Demo**, disponible en AWS Open Data sin ningún requisito de registro, proporciona datos reales de 100 pacientes suficientes para el desarrollo inicial de todos los módulos tabulares.

Synthetic Nursing Handover Dataset (Research Data Australia) contiene 300 audios WAV de handovers de enfermería simulados por actores entrenados, con sus transcripciones de referencia y las estructuras SBAR correspondientes anotadas manualmente. Este dataset es el ground truth para evaluar el módulo ASR+SBAR del proyecto. El estudiante debe calculaR qué porcentaje de los 300 audios se transcriben correctamente (WER global), con qué precisión se extraen las cuatro secciones SBAR, y cuáles son los errores más frecuentes (¿el modelo confunde nombres de medicamentos?, ¿falla en números?, ¿mezcla secciones?). Esa taxonomía de errores, presentada con ejemplos concretos, demuestra comprensión profunda del sistema más allá de las métricas agregadas.Revisar el siguiente contenido researchdata.edu

MIMIC-IV-Note contiene las notas clínicas de texto libre —incluyendo notas de enfermería— del mismo conjunto de pacientes de MIMIC-IV. Aunque requiere el mismo proceso de acceso que MIMIC-IV completo, proporciona ejemplos reales de cómo se escribe una nota nursing en urgencias, qué estructura tiene y qué información incluye. El Estudiante 2 debe analizar una muestra de estas notas (50-100) para entender el vocabulario, las abreviaturas y la estructura típica, y usar ese análisis para diseñar el template de nota nursing que el Agente Documental genera. Sin esta comprensión del dominio, el output del agente puede ser sintácticamente correcto, pero clínicamente irrelevante. Revisar el siguiente enlace emergentmind

El stack tecnológico: por qué mínimo y bien justificado

Una de las instrucciones más importantes de esta propuesta es que el estudiante **no debe acumular herramientas**. Cada librería adicional es una fuente potencial de incompatibilidades, bugs difíciles de depurar y tiempo perdido. El stack de UrgeNurse Agent está acotado a cinco dependencias principales:

- **Faster-Whisper**: ASR local. Es la única herramienta para transcripción de audio. No usar Whisper base ni ninguna otra alternativa en la versión principal.
- **Docling**: OCR y extracción de documentos. Es la única herramienta para procesamiento de PDF. No combinar con MinerU ni con Tesseract en el pipeline principal (pueden aparecer en la comparación del estado del arte).
- **Ollama + Mistral-7B**: LLM local para generación SBAR y clasificación. Un solo modelo para todas las tareas LLM. No usar modelos diferentes por tarea (salvo en el experimento de comparación con GPT-4o-mini).
- **LangGraph**: orquestación. Un solo framework de agentes. No mezclar con CrewAI ni con AutoGen.
- **Streamlit**: UI demo. Simple, funcional, sin necesidad de backend separado para la demo.

Cada una de estas elecciones debe justificarse en la memoria con una argumentación técnica, no simplemente con "es el más popular". Por ejemplo, la elección de Mistral-7B sobre Llama-3.2-3B se justifica porque Mistral tiene mejor desempeño en tareas de generación estructurada de texto (SBAR) según benchmarks públicos, mientras que Llama-3.2-3B es más adecuado para clasificación rápida donde la latencia importa más que la calidad de generación. Si el estudiante decide usar Llama-3.2-3B para el clasificador de triage y Mistral-7B para la generación SBAR, esa decisión diferenciada, bien argumentada con resultados empíricos comparativos, es exactamente el tipo de contribución técnica que eleva un TFM.

Evaluación: cómo medir que el sistema funciona

La sección de evaluación es donde más frecuentemente los TFM de IA pecan de superficialidad. Reportar una accuracy del 85% sin contexto no dice nada. El estudiante debe evaluar cada módulo de forma independiente, con sus métricas específicas, antes de evaluar el sistema integrado.

Para el **módulo de triage ESI**, la métrica principal es la concordancia entre el nivel ESI que el sistema calcula y el nivel ESI registrado en MIMIC-IV-ED. Aquí es importante matizar: no se trata de un modelo de clasificación que "aprende" a predecir el ESI, sino de un validador de reglas. La métrica relevante es qué porcentaje de casos el sistema detecta inconsistencias reales (un ESI 4 asignado a un paciente con FC 140 y saturación 88% debería haberse asignado ESI 2). El estudiante puede usar una sub-muestra de MIMIC-IV-ED donde se documentan revisiones de triage para validar esto.

Para el **módulo documental**, la métrica es Field-level F1: precisión y recall en la extracción de cada campo clave (hemoglobina, creatinina, glucosa…) sobre el conjunto de PDFs sintéticos con ground truth conocido. El estudiante genera los PDFs sintéticos con valores conocidos (puede usar Python + ReportLab para generar analíticas sintéticas con layouts variables), ejecuta el agente y compara los valores extraídos contra los valores reales. Esta evaluación controlada, aunque artificial, es metodológicamente sólida para un TFM.

Para el **módulo ASR+SBAR**, las métricas son WER (calculado con la librería jiwer de Python sobre el dataset Synthetic Nursing Handoff) y SBAR Completeness Score: qué porcentaje de las cuatro secciones SBAR tienen contenido no vacío en el output del sistema respecto al ground truth anotado en el dataset.

La evaluación del sistema integrado cierra con un experimento cualitativo: el estudiante presenta 5 escenarios completos (CSV triage + PDF analítica + audio handover) al pipeline, genera los outputs y los somete a una rúbrica de evaluación que incluye completitud, coherencia interna (¿los datos del SBAR son consistentes con los del triage validado?) y ausencia de alucinaciones (¿el SBAR cita solo información presente en los inputs?). Esa rúbrica, diseñada por el estudiante y aplicada sistemáticamente, es un instrumento de evaluación original que tiene valor metodológico propio.

Plan de Trabajo: cómo organizarse como equipo

La plantilla del Máster exige documentar la organización del trabajo grupal. Para un TFM de 18 semanas con tres estudiantes, la distribución más eficiente asigna a cada estudiante un módulo técnico como responsabilidad principal, con trabajo compartido en la integración, la evaluación y la memoria.

El Estudiante 1 lidera el Agente de Triage ESI y la ingestión de MIMIC-IV-ED. Esto implica exploración y análisis del dataset, diseño e implementación del validador de reglas ESI, y evaluación de concordancia. Su contribución individual en la memoria (Capítulo 5.1) debe demostrar comprensión del estándar ESI, análisis exploratorio de MIMIC-IV-ED con estadísticas descriptivas y visualizaciones, implementación documentada del agente, y evaluación con resultados cuantitativos.

El Estudiante 2 lidera el Agente Documental. Esto implica generación del dataset sintético de analíticas (al menos 4 layouts, 20 documentos por layout = 80 PDFs), evaluación de Docling sobre ese dataset, implementación del extractor de campos nursing y de la clasificación de alertas analíticas. Su capítulo individual debe incluir la metodología de generación de datos sintéticos, los resultados de evaluación de OCR por layout, y el análisis de errores con ejemplos.

El Estudiante 3 lidera el Agente ASR+SBAR. Esto implica análisis del dataset Synthetic Nursing Handoff, implementación de Faster-Whisper con VAD, diseño iterativo del prompt SBAR, evaluación WER y SBAR Completeness Score. Su capítulo individual debe incluir el análisis del dataset de handoff, el proceso de diseño del prompt (con al menos 3 versiones comparadas), los resultados de WER con análisis de errores por tipo y los resultados de extracción SBAR.

Las semanas 9-10 son críticas para el trabajo conjunto: integración de los tres agentes en LangGraph, diseño del PacienteState compartido, y primera prueba end-to-end con un expediente completo. Las semanas 13-14 son para la UI Streamlit y el experimento comparativo con GPT-4o-mini. Las semanas 15-18 son para la memoria completa, revisión del repositorio y preparación de la defensa.

La demostración en vivo durante la defensa es especialmente importante para este proyecto. El panel de evaluación debe poder ver al sistema procesar en tiempo real un CSV de triage MIMIC, un PDF de analítica sintético y un audio de handover de 2 minutos, y generar los tres outputs en menos de 3 minutos en el portátil del estudiante, sin conexión a internet. Esa demostración, si funciona de forma robusta, es el argumento más convincente de la viabilidad del enfoque local/CPU.